חיזוי זמני ניתוחי אף אוזן גרון

בשיתוף עם המרכז הרפואי הלל יפה

מגישים

- דין אליהו [redacted]
- לידור מכלוף [redacted]
- עמית ויסמן [redacted]

מנחה הפרויקט:

- ד"ר אבנר פריאל

צוות בית החולים:

- ד"ר נעה בריק
- ארז קריסי

פרויקט גמר

מסמך מסכם- חלק א'

תוכן עניינים

נושא וצוות הפרויקט.....1

רקע 3

עולם התוכן.....4

סקירת ספרות.....5

הגדרת הבעיות.....6

שאלת המחקר.....7

תיאור של גישת הפתרון.....8

ניתוח סט הנתונים.....10

התמודדות עם סט הנתונים.....13

תוצאות ראשוניות 15

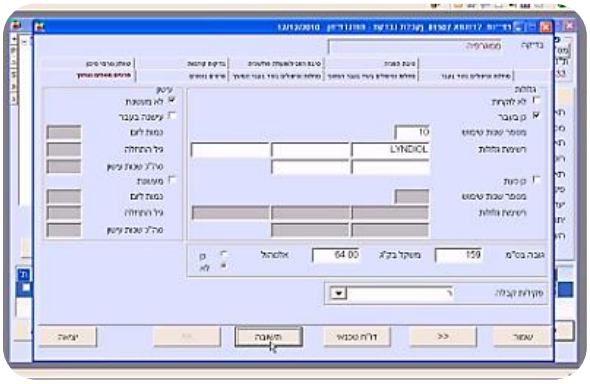
תכנית עבודה של הפרויקט ולוח זמנים.....18

רקע

- בתי חולים מהווים עוגן מרכזי במערכת הבריאות הציבורית, כאשר חדרי הניתוח מהווים את אחד מהמשאבים היקרים והמורכבים ביותר לניהול. תכנון לא נכון של זמני הניתוחים עלול להוביל לבזבוז זמן יקר, חוסר יעילות תפעולית, עומסי עבודה מיותרים לצוותים הרפואיים ולעיתים אף לפגיעה ברמת השירות למטופלים.
- בבית החולים הלל יפה מתבצעים ניתוחים יומיומיים במגוון מחלקות רפואיות, כאשר לכל מחלקה מוקצה חדר ניתוח בהתאם לזמינות.
- חדר הניתוח הינו יחידה קריטית הדורשת ניהול קפדני של לוחות הזמנים, ציוד רפואי, צוותי רפואה ותמיכה לוגיסטית.
- כיום, תהליך שיבוץ חדרי הניתוח מתבצע באופן ידני ע"י המזכירה הרפואית, המתבססת בעיקר על ניסיונה המקצועי והיכרותה עם נהלי המחלקה.
- עם זאת, השונות הרבה במורכבות הניתוחים, משך הזמן המשוער לכל פרוצדורה וההשפעות הבלתי צפויות (כגון סיבוכים רפואיים או עיכובים לוגיסטיים) מקשות על תכנון אופטימלי של סדרי העבודה.

מושגים בעולם התוכן

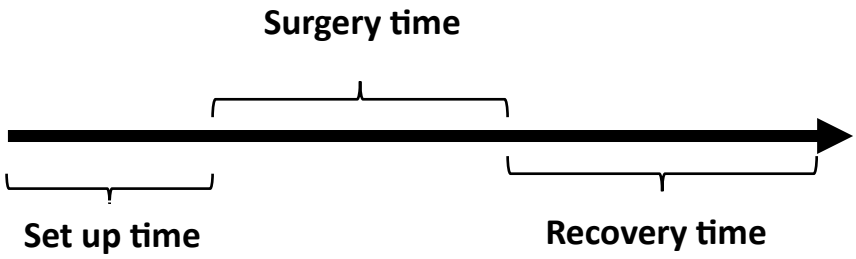
- Chameleon – מערכת המרכזת את התיק הרפואי של מטופל (הצוות הרפואי מסמן את זמני הניתוח במערכת)



- פרוצדורה – הליך או פעולה כירורגית על מטופל כחלק מניתוח (ניתוח יכול להכיל פרוצדורה אחת או יותר)



- זמן הכנה Set Up Time – הזמן הנדרש להכנת חדר הניתוח לפני התחלת הפרוצדורה, כולל סידור ציוד ואישור הצוות
- זמן התאוששות Recovery Time – משך הזמן שבו שוהה המטופל אחר הניתוח , עד שהוא מתייצב ויכול להשתחרר או להמשיך לטיפול אחר



- Surgery Time- הזמן הכולל מהתחלת הפרוצדורה ועד לסיומה.
- Anesthesia Time- משך הזמן בו המטופל נמצא תחת השפעת הרדמה.
- Preoperative Assessment- הערכה רפואית לפני הניתוח הכוללת בדיקות רקע רפואי, בדיקות דם ועוד.
- Postoperative Complications- סיבוכים רפואיים שעלולים להתרחש לאחר הניתוח ולהשפיע על זמן ההתאוששות.
- Predictive Modeling- תהליך בניית מודלים סטטיסטיים ומבוססי למידת מכונה לצורך חיזוי.

סקירה ספרותית

מודלים קיימים

מודלי חיזוי במערכת הבריאות : מחקרים שהציגו מודלים לניבוי כדי לתכנן משאבים ולשפר את לוחות הזמנים.

Montemayor, Cresmon Sagario. (2024, September). Transformative Impact of Predictive Modelling in Healthcare: Enhancing Patient Outcomes, Reducing Readmissions, and Optimizing Resource Allocation. *International Journal of Scientific Research and Engineering Development*, Volume 7, Issue 5, Pages 395-404.

IJSRED

פרטים המשפיעים על משך זמן הניתוח : פרטי המטופל , סוג הניתוח ושימוש בתוצאות ניתוחים קודמים, סוג הניתוח ומורכבותו.

Kurokawa, Takayuki, et al. (2024, September). CASEMIX Study: Assessment of Patient Factors Influencing the Subprocedure Duration of Trauma/Orthopaedic Surgeries. *Injury*, Volume 55, Supplement 3, Elsevier.

Injury Journal

שיטות עבודה

מודלים ללמידת מכונה : שיטות כמו ניתוח רגרסיה , יערות רנדומיים ורשתות נוירונים במחקרים קודמים כדי לחזות את משך זמן הניתוח (המחקרים הראו שניסיון הצוות הוא גורם משפיע על החיזוי).

Caserta, Marco, and García Romero, Antonio. (2024, July). A Novel Approach to Forecast Surgery Durations Using Machine Learning Techniques. *Health Care Management Science*, Springer.

Springer Link

שימוש בנתונים היסטוריים : שימוש בנתוני עבר כדי לחזות זמני פרוצדורות עתידיים (XGB הביא לתוצאות הטובות ביותר).

Riahi, Vahid, et al. (2023, December). Improving Preoperative Prediction of Surgery Duration. *BMC Health Services Research*, BioMed Central.

BMC Health Services Research

זיהוי פערים:

שילוב של מערכות זמן אמת : מספר מודלים משולבים בבתי החולים לחיזוי זמני הניתוח בזמן אמת.

Folio3 Digital Health. (2024, May). Predictive Modelling in Healthcare: Benefits and Use Cases. *Folio3 Digital Health Blog*.

Folio3 Digital Health

מחקרים פיננסיים:

Cheng, Hang, et al. (2018, April). Prolonged Operative Duration Is Associated with Complications: A Systematic Review and Meta-Analysis. Journal of Surgical Research, Academic Press.

Journal of surgical research Link

המרה ממחלה לקוד מחלה:

ICD-9 Disease Codes

הגדרת הבעיות

תכנון וניהול זמני ניתוחים בבתי חולים מהווים אתגר מורכב וקריטי להבטחת תפקוד תקין של המוסד הרפואי ולשמירה על איכות השירות למטופלים. חיזוי לא מדויק של משך הניתוחים עלול להוביל לשורה של בעיות מערכתיות ותפעוליות בעלות השלכות כלכליות ותפעוליות נרחבות:

- שיבוצים שגויים של חדרי ניתוח – תכנון לא מדויק עלול לגרום לעיכובים, דחיות וביטולי ניתוחים, מה שמוביל לאי שביעות רצון מצד המטופלים והצוות הרפואי.

- בזבוז משאבים כלכליים – חדרי ניתוח מהווים את אחד מהמשאבים היקרים ביותר במוסד רפואי. עיכובים או השבתות לא מתוכננות גורמים להפסדים כספיים משמעותיים (רלוונטי יותר לבית חולים פרטיים).

- עומסים תפעוליים בצוות הרפואי – אי תכנון נכון עלול להוביל לעומסי יתר על הצוותים הרפואיים ולפגיעה בפרודוקטיביות ובאיכות השירות.

- זמני המתנה ארוכים למטופלים – עיכובים בתהליך הניתוחי מובילים להארכת זמני ההמתנה של מטופלים לפני ואחרי הניתוח.

- עומסים בחדרי ההתאוששות ובמחלקות האשפוז – חיזוי שגוי של זמני ניתוחים משפיע על זמינות מיטות התאוששות ויוצר עומסים לא מתוכננים.

- חוסר שביעות רצון מצד מטופלים ובני משפחותיהם – אי עמידה בזמני הניתוחים המתוכננים פוגעת בחוויית המטופל ומפחיתה את תחושת הביטחון במערכת הרפואית.

השלכות אלה מדגישות את הצורך בפיתוח מערכת חיזוי מדויקת שתספק לצוותים הרפואיים כלי יעיל לתכנון משופר של זמני הניתוחים ולשיפור איכות השירות למטופלים תוך הפחתת עלויות תפעוליות ושימוש יעיל במשאבי בית החולים.

שאלת המחקר

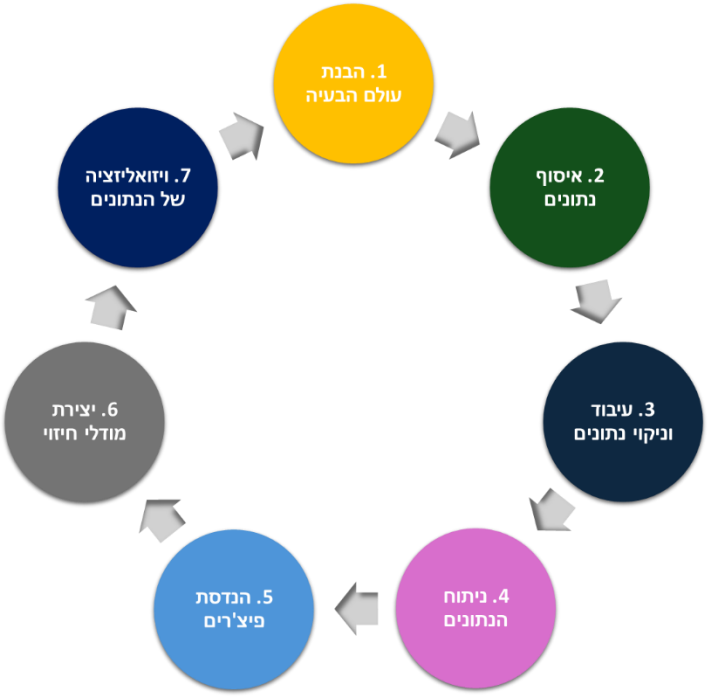
כיצד ניתן לחזות את זמן הניתוח של מטופל בעזרת נתונים על המטופל ובשימוש מידע על ניתוחי עבר?

תיאור של גישת הפתרון

הפתרון המוצע מתמקד בפיתוח מודל חיזוי מתקדם לזמני ניתוחים בהתבסס על נתוני עבר, תוך שימוש בטכניקות ניתוח נתונים ולמידת מכונה. המודל מאפשר חיזוי מדויק יותר של זמני הניתוח, מה שתורם לחיזוי מיטבי של זמני הניתוח, הפחתת עלויות תפעוליות ושיפור חווית המטופלים.

שימוש ב Data Life Cycle-לעבודה מסודרת ושיטתית

במהלך הפרויקט השתמשנו במחזור חיי הנתונים (Data Life Cycle) כדי להבטיח תהליך עבודה מובנה ויעיל. להלן פירוט השלבים שבוצעו:



1. הבנת עולם הבעיה:
   - ניתוח מעמיק של אתגרי התפעול בחדרי הניתוח ושל הצורך בחיזוי מדויק.
   - אפיון הגורמים אשר עלולים להשפיע על משך הניתוח כגון פרטי המטופל השונים, סוג הפרוצדורה ומאפייני הצוות הרפואי.
2. איסוף נתונים:
   - קבלת סט הנתונים שיובא מהמערכת Chameleon הכולל פרטים קליניים על המטופלים (גיל, מין , BMI, מחלות רקע) , נתוני הניתוח (סוג פרוצדורה, תאריכי ניתוח, זמני התחלה וסיום) ופרטים על הצוות הרפואי.
   - בניית מאגר נתונים שכלל מעל 4,000 רשומות ו-93 עמודות.
3. עיבוד וניקוי נתונים:
   - טיהור הנתונים מערכים חסרים ושגויים.
   - הסרת עמודות לא רלוונטיות.
   - זיהוי וניתוח ערכים חריגים והשפעתם על הנתונים.
4. ניתוח הנתונים:
   - חקירת הקשר בין פרמטרים שונים (כגון גיל, מין, BMI) למשך הניתוח.

- בחינת התפלגות זמני הניתוחים וניתוח קורלציות בין תכונות הנתונים לעמודת המטרה.
- זיהוי תכונות קריטיות שמשפיעות על משך זמן הניתוח.

5. הנדסת פיצ'רים:
   - המרה של משתנים קטגוריים לנתונים כמותיים באמצעות One-Hot Encoding.
   - נרמול של עמודות בעלות ערכים מספריים לפי טווח רפואי תקין (בדיקות דם , BMI לחץ דם וכו').
6. יצירת מודלי חיזוי:
   - בניית מספר מודלים לחיזוי זמני הניתוח, ביניהם XGB , רשתות נוירונים בעלות הייפר-פרמטרים שונים.
   - השוואה בין ביצועי המודלים ובחירה של המודל בעל התוצאה המדויקת ביותר נכון עד כה.
7. ויזואליזציה של הנתונים:
   - יצירת גרפים ותרשימים להמחשת התובנות שהופקו מהנתונים ולהבנת מגמות בצורה טובה יותר.

סיכום : בזכות עבודה שהתבצעה לפי שלבי ה Data Life Cycle-הצלחנו ליצור מודל חיזוי שמסייע לצוותי בית החולים לשפר את תהליך שיבוץ הניתוחים, להפחית עלויות ולשפר את חווית המטופלים.

ניתוח סט הנתונים

פרטי סט הנתונים:

- מספר שורות: 4,096 (כל שורה מייצגת ניתוח בודד)
- מספר עמודות: 93 (פרטי מטופלים, נתוני ניתוחים ותוצאות)

סוגי הנתונים שנאספו:

- נתוני מטופל:
- מאפיינים דמוגרפיים: גיל, מין
- מדדים קליניים: BMI, סטורציית חמצן (Oxygen Saturation), לחץ דם סיסטולי ודיאסטולי.
- הרגלי חיים: עישון (Smoker).
- מצב רפואי: מחלות רקע ואלרגיות.
- נתוני ניתוח:
  - פרטי הניתוח: קוד פרוצדורה (Procedure Code), סוג הניתוח (Surgery Type), יום הניתוח (Surgery Day).
  - מדדים תפעוליים: זמן הניתוח הכולל, סוג הרדמה.

עמודת הפרדיקציה (Target Variable):

- Total Surgery Time – משך זמן הניתוח הכולל (המדד המרכזי לחיזוי)
- רשומות לדוגמה (מתוך סט הנתונים):

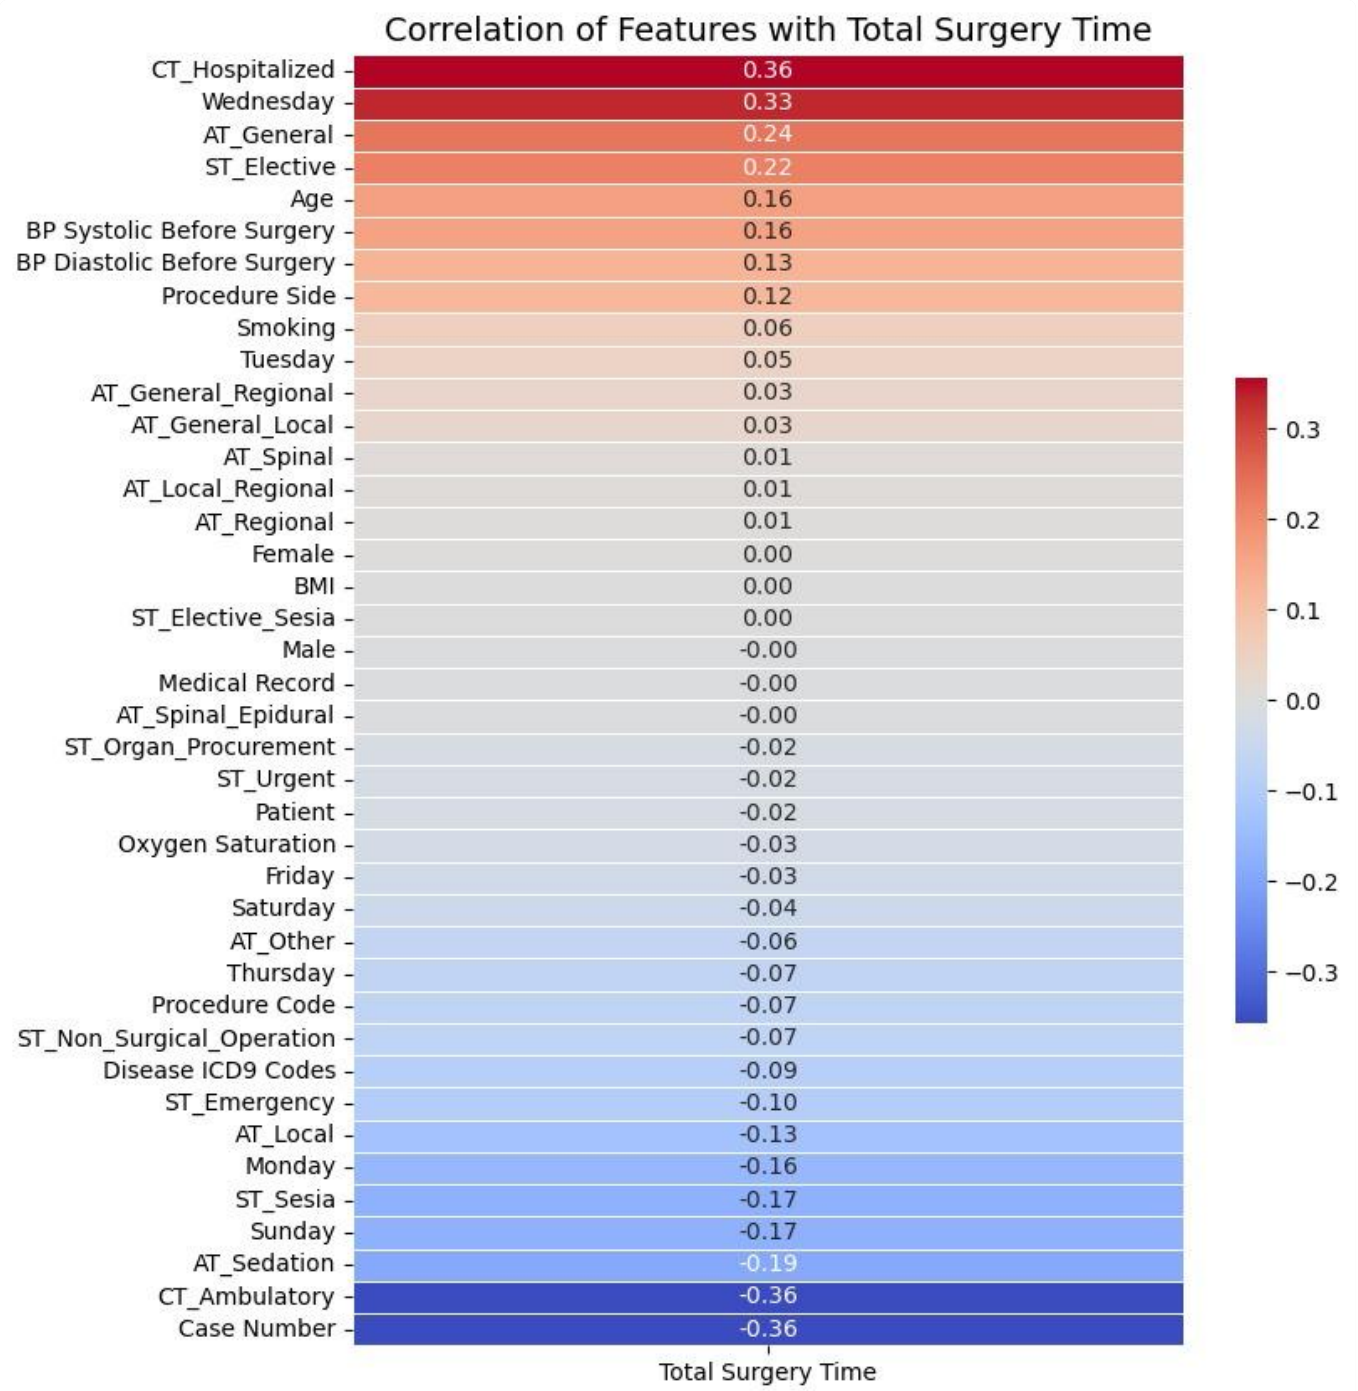
Patient	Medical Record	Case Number	Age	Male	Female	BMI	Procedure Code	Procedure	Oxygen Saturation	BP Systolic	BP Diastolic
366	482527	11070984	40	0	1	41.522491	28.2	0	0.97	-0.013274	0.68621938
555	706414	11132211	56	0	1	35.996326	21.69.05, 22.19.02	1	0.97	0.4971552	0.86503209
798	565911	11093427	24	0	1	31.25	21.69.05, 28.6.02	1	1	-0.11536	-1.3701267
802	925949	11191011	47	0	1	27.475629	22.19.02	1	0.98	-1.034134	-0.2078441
847	1094489	11240764	37	1	0	17.28395	28	0	0.98	-0.013274	-0.1184378
889	1434082	11476685	48	0	1	37.109375	30.09.02, 31.42.09, 31.43.01	0.5	0.97	0.9565419	0.50740668
1006	1384919	11464969	30	1	0	31.141868	06.09.05	0.5	0.99	-0.11536	0.50740668

- <u>עמודות ייחודיות:</u>

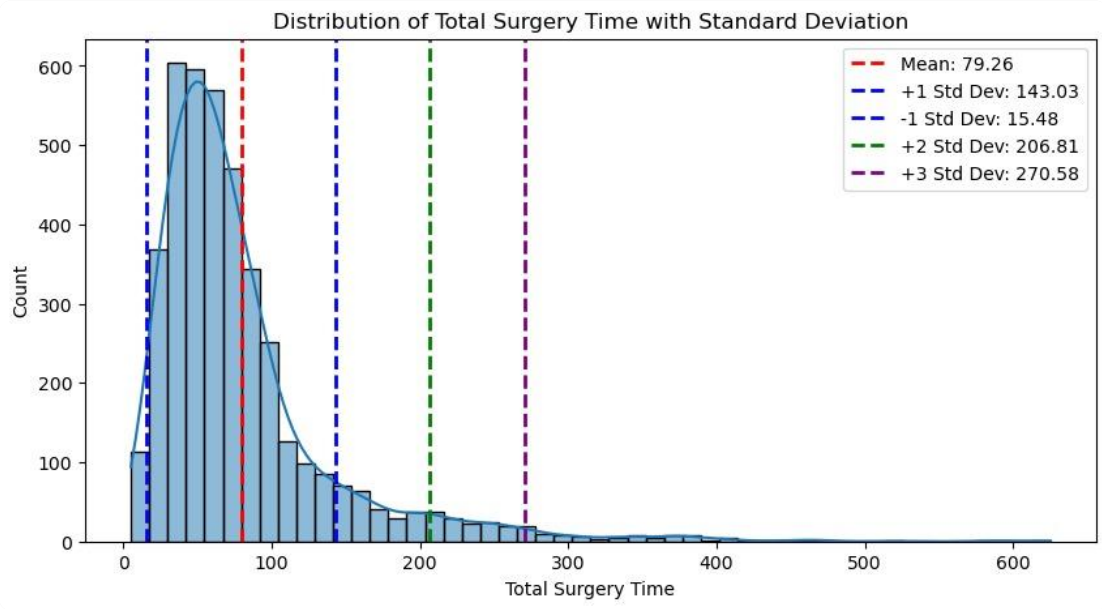
עמודה	כמות ערכים ייחודיים
Age	99
BMI	2261
Procedure Code	423
Procedure Side	3
Oxygen Saturation	15
BP Systolic Before Surgery	117
BP Diastolic Before Surgery	76
Drug Names	907
Allergy Drug Names	316
Disease ICD9 Codes	814
Total Surgery Time	320

- עמודת המטרה – זמן הניתוח

• <u>קורלציה לעמודת המטרה</u>



- <u>ההתפלגות של זמני הניתוח:</u>



תובנות מהגרף – התפלגות זמני הניתוחים:

התפלגות הנתונים (Distribution Analysis):

- הגרף מציג התפלגות חיובית מוטה של זמני הניתוחים – רוב הניתוחים נמשכים פחות מ-100 דקות, אך קיימים מקרים יוצאי דופן בהם הניתוחים מתארכים משמעותית.
- הממוצע של זמן הניתוח: 79.26 דקות, כפי שמסומן בקו האדום בגרף.
- החציון ככל הנראה נמוך מהממוצע בשל ההטיה, דבר המעיד על קיומם של ניתוחים חריגים בעלי זמן ארוך במיוחד.

סטיות תקן והשפעתן (Standard Deviation):

- סטיית תקן ראשונה (+1/-1):
רוב הניתוחים (כ-68% מהנתונים) מתרכזים בטווח שבין 15.48 דקות ל-143.03 דקות.
- סטיות תקן שנייה ושלישית (+2/+3):
חריגות מעבר ל-206.81 דקות (קו ירוק) ול-270.58 דקות (קו סגול) נדירות יחסית ומהוות קיצוניות.
- ניתוחים בטווחים אלו עשויים להיות מורכבים יותר או מלווים בסיבוכים בלתי צפויים.

ניתוח חריגים (Outliers):

ניתן לראות כי קיימים ניתוחים החורגים באופן מובהק מהממוצע, ואף מגיעים ליותר מ-600 דקות.
ניתוחים אלו עשויים להשפיע על תוצאות המודלים ולגרום להטיות, ולכן חשוב לשקול את השפעתם על תהליך החיזוי.

תובנות לפעולה:

- הקטנת השפעת חריגים: ניתן לשקול להפעיל שיטות זיהוי וסינון חריגים (כגון IQR או Z-Score) לפני הכשרת המודל כדי להימנע מהשפעות של מקרים קיצוניים.
- פילוח לפי סוגי ניתוחים: ניתוחים שונים עשויים להציג דפוסי זמן שונים. פילוח נתוני הניתוחים לפי סוג עשוי לשפר את הדיוק בחיזוי.
- שקלול על בסיס מורכבות הניתוח: הוספת פיצ'רים נוספים הקשורים למורכבות הניתוח (כגון מספר פרוצדורות) עשויה להסביר טוב יותר את הסטיות.

התמודדות עם סט הנתונים

האתגרים בעיבוד הנתונים:

1. ערכים חסרים: טיפול בערכים חסרים בעמודות קריטיות באמצעות שיטות השלמה (כגון ממוצע/חציון) או השמטת שורות לא רלוונטיות.
2. הטרוגניות הנתונים: שילוב בין נתונים מספריים, קטגוריאליים ובינאריים דרש המרה לפורמטים אחידים (One-Hot Encoding, Normalization).
3. חריגים והשפעתם: זיהוי ערכים קיצוניים (Outliers).

מטרות תהליך עיבוד הנתונים:

- לאפשר הכשרת מודלים מדויקים על ידי ניקוי והכנת הנתונים.
- לזהות אילו פיצ'רים משפיעים באופן מהותי על משך זמן הניתוח.
- להבטיח שהנתונים תואמים את דרישות המודלים שנבחרו.

ניקוי סט הנתונים

ערכים חסרים

- במהלך תהליך ניקוי סט הנתונים זוהו ערכים חסרים בעמודות מרכזיות כמו Total Surgery Time (126 רשומות), Weight (240 רשומות) ו-BMI (1511 רשומות).
- ההתמודדות עם החסרים בוצעה בהתאמה: ערכים חסרים בעמודת זמן הניתוח נמחקו בשל חשיבותם לפרדיקציה, בעוד שערכים חסרים במשקל וב-BMI הושלמו באמצעות חישוב ממוצע בהתאם לקבוצות גיל ומין.
- בנוסף, בעמודת Disease ICD9 Codes (2953 רשומות חסרות) הוחלט להשלים ערכים חסרים כ-"0" לציון היעדר מידע רפואי נוסף.

עמודה	כמות ערכים חסרים	פתרון
Total Surgery Time	126	מחיקת השורות
Weight	240	השלמה לפי ממוצע בהתאם לגילאים
BMI	1511	השלמה לפי גובה ממוצע לפי גילאים
Disease ICD9 Codes	2953	השלמה ל 0

עמודות טקסטואליות

- במהלך עיבוד הנתונים הטקסטואליים בוצעה התאמה של העמודות הטקסטואליות לפורמט כמותי.
- עמודות קטגוריאליות כמו Surgery Type ו-Anesthesia Type קודדו באמצעות One Hot Encoding לצורך שמירה על מבנה הנתונים ולמניעת השפעה של ערכים סדרתיים.
- עבור עמודת Drug Name, שבה מגוון רחב של ערכים, נעשה שימוש ב-Word Embedding כדי לייצג את הקשרים בין התרופות באופן מדויק יותר.

- בנוסף, עמודת Procedure Side הומרה לערכים מספריים (0, 0.5, 1) בהתאם לצדי הגוף, ועמודת Case Type קודדה בינארית להבחנה בין מקרים אמבולטוריים לאשפוזיים.
- שלבים אלו אפשרו התאמה של הנתונים לאלגוריתמים סטטיסטיים ולמידת מכונה.

עמודה	פתרון	סיבה לפתרון
Procedure Side	• 0 עבור ערך ריק • 0.5 עבור צד 1 • 1 עבור 2 צדדים	
Surgery Type	One Hot Encoding	פיצול ל-7 עמודות
Anesthesia Type	One Hot Encoding	פיצול ל-10 עמודות
Drug Name	Word Embedding	
Case Type	One Hot Encoding	• 1 - אמבולטורי • 0 - אשפוז

תוצאות ראשוניות

השוואות בין מודלים שונים

- תהליך השוואת המודלים בוצע באמצעות ספריית PyCaret, אשר אפשרה בחינה מהירה ויעילה של מספר מודלי רגרסיה.

- פלט הרצת הקוד :

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE
rf	Random Forest Regressor	26.0195	1790.4564	42.0141	0.5434	0.4215	0.3701
et	Extra Trees Regressor	25.2340	1787.1966	42.0056	0.5429	0.4171	0.3435
gbr	Gradient Boosting Regressor	28.0653	1831.6046	42.5538	0.5323	0.4513	0.4392
omp	Orthogonal Matching Pursuit	26.1186	2206.6195	46.0241	0.4581	0.4572	0.3720
lightgbm	Light Gradient Boosting Machine	29.0402	2166.7006	46.1878	0.4540	0.4606	0.4392
ada	AdaBoost Regressor	39.0800	2758.1943	52.3923	0.2911	0.6151	0.7482
dt	Decision Tree Regressor	33.7649	2920.1164	53.7405	0.2457	0.5564	0.4674
lasso	Lasso Regression	33.7257	3433.0233	55.3980	0.1974	0.5559	0.5284
llar	Lasso Least Angle Regression	33.7257	3433.0233	55.3980	0.1974	0.5559	0.5284
ridge	Ridge Regression	34.7607	3421.2572	55.9843	0.1859	0.5957	0.5632
br	Bayesian Ridge	42.3518	3563.7750	58.5031	0.1148	0.7792	0.8420
en	Elastic Net	36.3401	4138.5969	60.7480	0.0333	0.5568	0.5767
dummy	Dummy Regressor	41.9817	3963.5179	62.6518	-0.0031	0.6875	0.7844
knn	K Neighbors Regressor	43.1941	4250.1457	64.9286	-0.0820	0.6520	0.6886
huber	Huber Regressor	45.8492	5188.9160	71.7257	-0.3179	0.8420	0.6428
par	Passive Aggressive Regressor	52.6731	6149.9303	77.9716	-0.5582	0.9126	0.8820

- המודל Extra Trees Regressor הציג את הביצועים הטובים ביותר:
  - MAE = 25.23
  - MSE = 1787.1966
  - RMSE = 42.0056
  - R2 = 0.5429

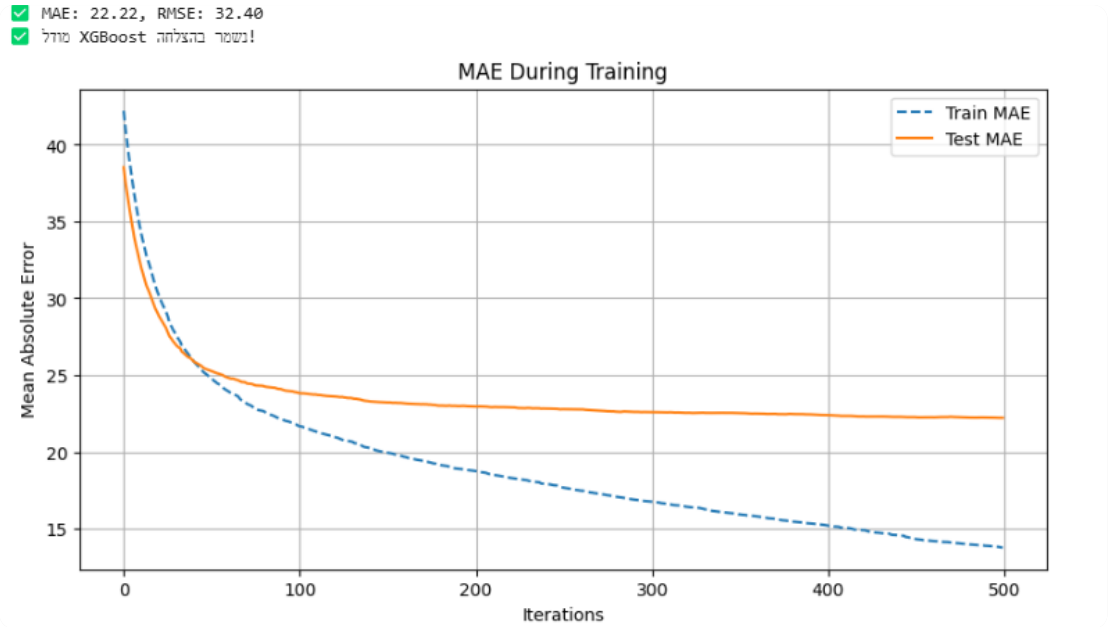
- מודלים מבוססי עצים (כגון Random Forest ו-Gradient Boosting) הראו גם הם ביצועים טובים ביחס לשאר המודלים שנבדקו.

המודלים בעלי התוצאות המדויקות ביותר

דוגמאות לחלק מעשרות המודלים השונים שבנינו (רשתות נוירונים , XGB , היברידי)

XGBoost

- נתוני ביצועים עיקריים:
  - MAE = 22.22 min
  - RMSE = 32.4 min



- ניתוח גרף ה-MAE לאורך האיטרציות:
- התייצבות והפרדה בין Train ל-Test:

לאחר כ-100 איטרציות, ניתן לראות פיצול בין Train MAE (הולך ויורד) לבין Test MAE (מתייצב סביב 22.22).

פער זה מצביע על כך שהמודל ממשיך ללמוד את הדאטה באימון אך שומר על יציבות במבחן מבלי "לזכור" את הנתונים.

- הימנעות מ-Overfitting:

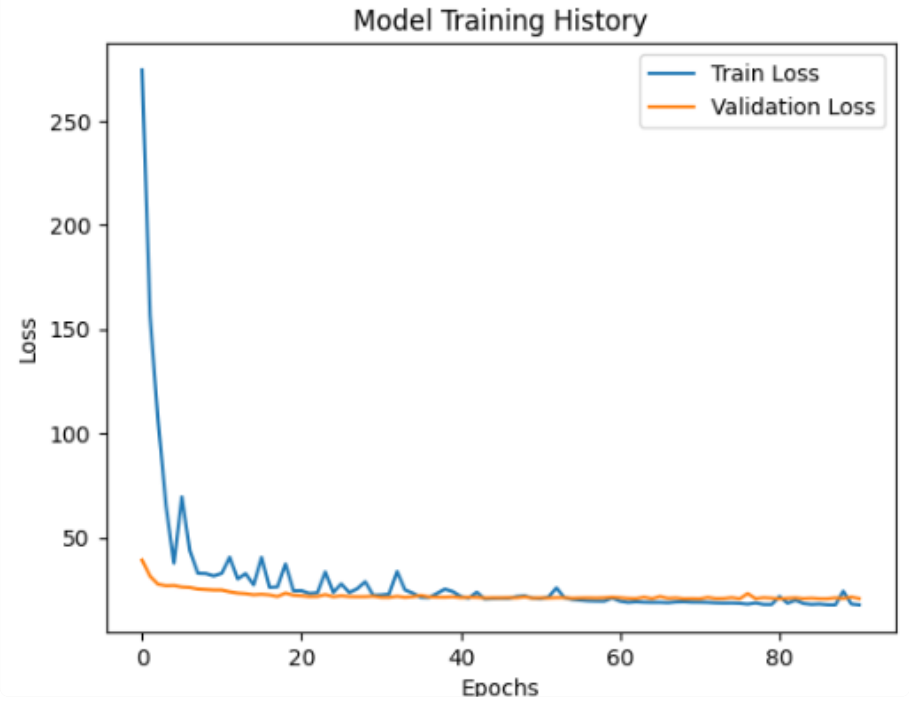
למרות ירידה עקבית ב-Train MAE עד כ-15 דקות, ה-Test MAE נשאר יציב יחסית סביב 22.22 דקות לאחר ~250 איטרציות.

זה מעיד על כך שהמודל נמנע מ-Overfitting בזכות מנגנוני Regularization המובנים ב-XGBoost כמו שימוש ב-Tree Pruning ו-early stopping מובנה.

רשת נוירונים

- ביצועים:
  - MAE=20.98 min
  - RMSE=32.48 min
- מבנה הרשת:
  - שכבות נסתרות 3 :שכבות (256, 128, 64 נוירונים בהתאמה).
  - פונקציית אקטיבציה – *Leaky ReLU* למניעת "נוירונים מתים" ולשמירה על זרימת מידע ברשת.
  - Dropout: ערך של 0.3 להקטנת Overfitting.
  - Early Stopping: עצירה אוטומטית כאשר אין שיפור נוסף ב Validation Loss-למניעת אימון יתר.

```
Test Loss: 20.49, Test MAE: 20.98
26/26 ━━━━━━━━━━━━━━━━━━━━ 0s 4ms/step
Test RMSE: 32.48 minutes
```



- תובנות מהגרף:

הגעה ליציבות יחסית:

- לאחר כ-20 Epochs, ה Validation Loss-מתייצב עם שינויים מינימליים, מה שמעיד על כך שהמודל מצא נקודת שיווי משקל בין למידת יתר ללמידה טובה.
- הפער הקטן בין ה Train Loss-ל Validation Loss-מצביע על כך שהמודל מצליח לשמור על יציבות מבלי להיכנס למצב של Overfitting.

תכנית עבודה של הפרויקט ולוח זמנים

סמסטר א'

שבוע	משימה	תוצאות	תובנות ומשימות להמשך
1-2	הכרה והבנה של עולם התוכן חיזוי ניתוחים	צוות הפרויקט הבין את המושגים מעולם הבעיה	○ פגישה עם מנחה הפרויקט להבנת המשימות להמשך ○ פגישה עם הצוות העוזר מ-הלל יפה לקבלת מידע נוסף
2-4	קבלת מסד נתונים ראשוני	הכרת ה-chameleon ניתוח ראשוני של הנתונים	○ ניקוי הדאטה ○ חיפוש ומחקר אחר פיצ'רים בעלי קורלציה לזמן הניתוח ○ מודל ראשוני
4-6	ניקוי הנתונים יצירת מודל ראשוני	הבנת הבעיות בנתונים הקיימים חיזוי זמן הניתוח עם טעות ממוצעת של 32 דקות	○ יש להבין איך להתמודד עם ערכי קיצון ועם ערכים חסרים ○ יש להבין איך להתמודד עם עמודות מלל ○ בקשת נתונים נוספים מארז ראש מערכות המידע של הלל יפה
6-8	פגישה עם ארז ראש מערכות המידע ועם ד"ר נעה בריק כדי להבין אילו נתונים נוספים יש להוסיף ל-Dataset	נתונים חדשים על ניתוחים קודמים ועל בדיקות של מטופל	○ יש לנקות את הנתונים החדשים ○ ליצור מספר מודלים חדשים ובחירה על המודל הטוב ביותר ○ מציאת פתרון לעמודות טקסטואליות
8-14	ניקוי הנתונים ויצירת מודל שני	זמן החיזוי הפך למדויק יותר זמן החיזוי עם טעות ממוצעת של 22.5 דקות	○ השלמת ערכים חסרים ○ עמודות טקסטואליות

סמסטר ב' – משימות להמשך

שבוע	משימה
15-16	המשך הבנת הנתונים בעזרת ד"ר נעה בריק ומחקר עצמאי
16-18	בדיקת אפשרויות שונות לקידוד המשתנים הקטגוריים (למשל מ-Word Embedded ל-One Hot Encoding)
18-20	בדיקת מודלים נוספים עם פרמטרים שונים
20-22	הנדסת הפיצ'רים לקבלת זמני ניתוח מדויקים יותר
22-...	ייעול המודל בטוב ביותר שמצאנו

סיכום משימות להמשך :

- העמקת תהליך הנדסת הפיצ'רים (Feature Engineering):

זיהוי יצירתי של פיצ'רים חדשים שעשויים להשפיע על משך זמן הניתוח (כגון מורכבות הניתוח, ניסיון המנתח, סוג הציוד הרפואי).

יצירת פיצ'רים מבוססי נתונים קיימים (כגון חישוב יחס בין גיל למחלות רקע או זמן ההמתנה לחדר הניתוח).

- בחינת מודלים מתקדמים נוספים:

שילוב מודלים מורכבים שיכולים להתמודד טוב יותר עם נתונים קטגוריאליים.

בדיקה של מודלים היברידיים (שילוב רשת נוירונים עם XGBoost) לשיפור יכולות החיזוי.

- שיפור איכות הנתונים (Data Quality):

זיהוי והסרה של רעשי מידע או ערכים חריגים העלולים להשפיע על דיוק המודל.

- שיפור תהליך האימון (Model Training):

ביצוע Hyperparameter Tuning מעמיק יותר כדי לאתר את הפרמטרים האופטימליים לכל מודל.

- ניתוח שגיאות המודל (Error Analysis):

בדיקת מקרים שבהם המודל נכשל או סיפק חיזוי לא מדויק, כדי להבין מה גרם לשגיאה ולבצע התאמות בהתאם.

פילוח השגיאות לפי סוגי ניתוחים או מאפייני מטופלים לבדיקה האם יש דפוסי טעויות חוזרים.

- בדיקות נוספות על קבוצות משנה:

ביצוע חיזויים על קבוצות מטופלים מסוימות (כגון חולים כרוניים או מבוגרים) או על סוגי ניתוח שונים (פרוצדורות שונות) כדי לבדוק האם נדרשים מודלים מותאמים לכל תת-אוכלוסייה.